

Муниципальные траектории

Динамическая сеть сходства потребления

Конкурс исследовательских проектов СберИндекса. Номинация «Кластеризация». Данные за 2023–2024 годы. Расчёты от 4 октября 2026 года; редакция от 6 октября 2026 года.

1. Задача исследования

Цель работы состоит в выявлении муниципалитетов с близкими потребительскими профилями и изучении изменений этих профилей в течение 2024 года. Экономическое сходство позволяет подбирать территории для сравнения за пределами соседних районов. Анализ переходов между группами помогает выделить изменения, которые заслуживают отдельного изучения.


По полной панели из 2 016 муниципалитетов построены 12 месячных взвешенных сетей. Вершины соответствуют территориям, их атрибуты описывают расходы жителей, рёбра соединяют близкие профили. Сообщества выделены алгоритмом Leiden. Сопоставление составов групп в соседних месяцах определяет переходы территорий. Структура и уровень расходов образуют один блок признаков, годовые темпы изменения другой; оба блока имеют одинаковый масштаб вклада.

Получены три крупных профиля потребления. Из 2 653 смен меток 49 событий в 40 территориях прошли заданную проверку локальной устойчивости. Среднегодовая месячная доля маркетплейсов выросла во всех территориях панели, медианный прирост составил 4,10 процентного пункта. Около половины декабрьских связей с известным дорожным расстоянием соединяют центры, удалённые более чем на 1 000 км.

В сравнении моделей наибольшую совокупную оценку получил K-means с шестью группами. Для анализа сетевых сообществ выбрана лучшая допустимая конфигурация Leiden. Низкая разделимость групп и чувствительность отдельных месяцев ограничивают интерпретацию переходов. Результат представляет описание структуры потребления в выбранном масштабе; для установления причин изменений нужны внешние данные.

Интерактивная страница объединяет проекцию пространства признаков, карточки территорий, историю групп и список близких муниципалитетов. Расчёты, параметры моделей и помесечные результаты входят в репозиторий.

Экономическое пространство, декабрь 2024



2. Данные и проверка качества

Использованы три файла официального муниципального набора СберИндекса: `consumption.parquet`, `connection.parquet` и `market_access.parquet`. Таблица потребления содержит 303 126 строк за 24 месяца и 2 190 уникальных `territory_id`. Полная история всех категорий доступна для 2 016 территорий, или 92,05% исходного числа. В анализ включена эта сбалансированная панель. Остальные 174 территории исключены; заполнение пропусков не проводилось. Состав панели и исключённые ID приведены в `territory_coverage.csv`. Различия между включёнными и исключёнными территориями требуют отдельной оценки.

Согласно описанию источника, показатель является модельной оценкой средних месячных безналичных расходов жителей в рублях. Его область измерения ограничена потребительскими расходами; он не характеризует напрямую доходы населения или оборот торговли на территории. Муниципалитеты имеют одинаковый вес. Денежные величины и темпы изменения приведены в номинальном выражении.

В исходной таблице значения хранятся в поле `value`, в описании набора показатель назван `consumption`. Код поддерживает оба варианта. Пропусков полей и повторов ключа «территория, месяц, категория» не обнаружено, все значения положительны. Показатель «Все категории» используется как знаменатель. Категория «Прочие расходы» рассчитана как разность общего показателя и суммы пяти частных категорий. Во всех наблюдениях панели остаток неотрицателен.

В таблице транспортных расстояний 5 942 364 записи. Для автодорог повторов неориентированных пар нет; для железных дорог обнаружено 1 319 314 обратных повторов. В сравнении с экономической сетью используются автодороги. Нулевые расстояния между разными ID сохранены, неизвестные расстояния учитываются как пропущенные. Набор описывает состояние на конец 2024 года и используется ретроспективно.

Индекс доступности рынков имеется для 2 004 территорий панели и отсутствует для 12. По описанию источника это нормированный показатель внешнего населения, взвешенного по дорожной удалённости. Индекс оставлен для внешнего сопоставления результатов и исключён из признаков и выбора модели. Его связь с географией учитывается при интерпретации.

Названия территорий получены по ID из вторичного публичного справочника. Все 2 016 ID сопоставились однозначно. Названия и коды ОКТМО используются для подписей и поиска; административное устройство в справочнике может отличаться от исследуемого периода. Ключом результатов служит `territory_id`. Постоянство границ заявлено в описании СберИндекса, независимая проверка геометрии не проводилась.

3. Признаки и построение сети

Профиль потребления описан семью признаками. Шесть из них представляют квадратные корни долей расходов, усреднённых за текущий и два предыдущих месяца. Такое преобразование уменьшает влияние крупных категорий. Седьмой признак равен логарифму общих расходов за вычетом медианного логарифма по территориям в том же месяце. Окно сглаживания включает только текущие и предшествующие наблюдения.

Динамику характеризуют шесть логарифмических годовых темпов: общих расходов и пяти частных категорий. Из каждого темпа вычтена его медиана по муниципалитетам текущего месяца. Центровка выделяет относительную динамику территорий на фоне общего изменения номинальных расходов. Для перехода к реальным темпам потребовались бы региональные дефляторы.

Медианы и межквартильные размахи RobustScaler оценены по январю, марту и июню 2024 года. Стандартизованные значения ограничены интервалом $[-6, 6]$. Каждый блок делится на квадратный корень числа своих признаков и на квадратный корень из двух. Полученное 13-мерное пространство уравнивает масштаб двух блоков. Коэффициенты преобразований сохранены в `transformations.json`.

Для каждого месяца найдены k ближайших соседей по евклидову расстоянию. Неориентированный граф содержит ребро, если хотя бы одна вершина выбрала другую. Вес задан формулой $w(i,j) = \exp(-d(i,j)/\tau)$, где τ равна медиане положительных расстояний по выбранным направленным соседствам. Петли удалены, матрица смежности симметрична. В основной модели $k = 40$. Рёбра характеризуют сходство расходов жителей, без предположения о транспортных или торговых потоках между территориями.

Leiden оптимизирует `RBConfigurationVertexPartition` с разрешением 0,4 и начальным значением генератора 42. Месячные сети кластеризуются отдельно, межвременные рёбра и штраф за смену группы отсутствуют. Метки соседних месяцев сопоставлены венгерским алгоритмом по максимальному пересечению составов. Таблица `cluster_flows.csv` содержит все потоки между группами, включая расщепления и объединения.

Схема анализа ретроспективная. Коэффициенты нормировки, рассчитанные в том числе по июню, применены к ранним срезам 2024 года. Данные июля–декабря исключены из оценки этих коэффициентов и выбора конфигурации. Применение в режиме текущего мониторинга потребовало бы последовательной настройки только по информации, доступной на каждую дату.

4. Оценка качества и выбор модели

Сопоставлены 24 конфигурации: 18 вариантов Leiden и по три варианта K-means и Ward. Для Leiden рассмотрены три набора признаков графа, $k = 20/40$ и разрешение $0,4/0,8/1,2$. Для K-means и Ward заданы 4, 6 и 8 групп. Атрибутивные индексы рассчитаны в общем 13-мерном пространстве. Индексы AVI, AVU и MQ для всех разбиений одного месяца используют общий опорный граф с $k = 30$ по объединённым признакам.

Индекс	Предпочтение	Определение
SW	Больше	Средний silhouette по евклидовым расстояниям
CH	Больше	Calinski-Harabasz в реализации sklearn
S_Dbw	Меньше	Рассеяние и плотность между центрами
AVI	Больше	Средняя доля внутреннего веса в объёме группы
AVU	Меньше	Средняя объединяемость групп по внешним связям
MQ	Больше	Взвешенная модульность Ньюмана-Гирвана, $\gamma = 1$

Индексы AVI и AVU реализованы как весовая адаптация формул Shalileh, Antonov, Tsyplakova (2025). Пусть $B = H' A H$, H обозначает матрицу принадлежности, A симметричную взвешенную матрицу смежности. Тогда $v_i = \sum_j B_{ij}$, $e_i = v_i - B_{ii}$; $AVI = \text{mean}_i(B_{ii}/v_i)$; $AVU = \sum_{i \neq j} [B_{ij}/(e_i + e_j - B_{ij})]/K$. При нулевом знаменателе вклад принимается равным нулю. Модульность рассчитана как $MQ = \sum_i [B_{ii}/\sum(v) - (v_i/\sum(v))^2]$.

В S_Dbw используются популяционная дисперсия и число точек внутри заданного радиуса. Радиус равен $\sqrt{(\sum_i ||\text{var}(C_i)||)/K}$. При нулевой плотности в обоих центрах и положительной плотности между ними индекс принимает значение бесконечности. Такие значения сохранены в CSV и получают худший ранг. Конвенция указана явно, поскольку реализации S_Dbw могут различаться.

Совокупная оценка включает 40% среднего процентильного ранга SW, CH и обратного S_Dbw , 40% ранга AVI, обратного AVU и MQ, а также 20% ранга среднего ARI трёх дополнительных запусков в июне. К выбору допущены конфигурации с 3–12 группами и минимум 20 территориями в каждой на всех трёх срезах настройки. Веса задают принятый в работе баланс критериев. Полная таблица `selection_summary.csv` позволяет оценить альтернативные предпочтения.

Настройка выполнена на январе, марте и июне. Июль–сентябрь использованы для валидации, октябрь–декабрь для заключительной проверки. Февраль, апрель и май включены в описание траекторий. После настройки параметры зафиксированы. Временная зависимость соседних месяцев ограничивает независимость заключительной проверки.

5. Сравнение методов

K-means с шестью группами получил на срезах настройки оценку 0,784. Лучший допустимый вариант Leiden набрал 0,724. Средний ARI трёх дополнительных запусков в июне составил соответственно 0,993 и 0,757. Для изучения сообществ сети выбран этот вариант Leiden, результаты K-means используются при сравнении.


Метод, декабрь 2024	K	SW	CH	S_Dbw	AVI	AVU	MQ
Leiden, k40, r0,4	3	0,149	389,82	0,928	0,904	0,667	0,544
K-means(6)	6	0,145	332,40	0,736	0,727	0,489	0,557
K-means(8)	8	0,143	283,91	0,679	0,669	0,446	0,550

У Leiden выше доля внутреннего веса связей. Частично это связано с крупным размером и меньшим числом групп. Индексы реагируют на число кластеров по-разному, поэтому сравнение учитывает весь набор метрик вместе с размерами сообществ.

Средний silhouette за октябрь–декабрь равен 0,120 для Leiden, 0,148 для K-means(6) и 0,147 для K-means(8). Все три значения указывают на слабую разделимость. В декабре 16,9% территорий основной модели имеют отрицательный индивидуальный silhouette. Высокая поддержка метки при изменении параметров может сочетаться с таким результатом: воспроизводимость назначения группы и её геометрическая отделимость характеризуют разные свойства.

Ward представлен в полном сравнении на срезах настройки. Дополнительная кластеризация дорожного графа методом Leiden дала 21 группу, включая изолированные вершины. ARI между географическим разбиением и тремя экономическими группами равен 0,072 на территориях с дорожными соседями. Разное число групп ограничивает сопоставимость; результат используется для описания различий двух структур.

В random_baselines_december.csv представлены 20 случайных перестановок декабрьских меток с сохранением размеров групп. Они дают ориентир для оценки метрик относительно случайного назначения. Пространственная зависимость в перестановках не учитывается, выводы о статистической значимости по ним не делаются.



6. Профили потребления

Названия групп отражают медианные характеристики декабря 2024 года. Они используются для навигации по результатам. Содержательная интерпретация каждой группы опирается на её профиль в выбранном месяце; классификация благосостояния или отраслевой специализации в работе не проводится.


Декабрь 2024	Территорий	Медиана расходов, руб./мес.	Продукты	Маркетплейсы	Общепит
C0. Базовая корзина	1 098	27 658,5	44,8%	21,2%	1,3%
C1. Смешанный профиль	610	39 715	40,1%	17,4%	3,3%
C2. Высокие расходы и услуги	308	59 604	32,1%	16,1%	6,5%

В таблице приведены медианы индивидуальных долей внутри групп. Поскольку медианы рассчитаны по каждой категории отдельно, их сумма может отличаться от 100%. В карточке отдельной территории шесть долей образуют полную структуру расходов.

Средняя за 12 месяцев доля маркетплейсов увеличилась во всех 2 016 территориях панели. Медиана индивидуального прироста между 2023 и 2024 годами составила 4,10 п.п. Медианный номинальный прирост средних месячных общих расходов равен 15,12%. Оба результата характеризуют муниципалитеты при одинаковом весе каждой территории. Для оценки общероссийской динамики потребовалось бы взвешивание по населению.

Группа C0 сочетает более высокую долю маркетплейсов с меньшим уровнем общих расходов. Это подчёркивает значение знаменателя при сравнении долей. Переходы между группами зависят от совокупности структуры, уровня и темпов расходов; общий рост маркетплейсов описывает лишь одну часть этой динамики.

Медианы долей расходов по группам, декабрь 2024



7. Переходы и чувствительность

Для каждого месяца рассчитаны девять альтернативных разбиений: пять начальных значений генератора, $k = 30/50$ и разрешение $0,36/0,44$. После сопоставления групп поддержка территории определяется как доля вариантов, сохранивших её метку. Она характеризует чувствительность к заданным изменениям параметров. Статистическая вероятность правильной классификации этой процедурой не оценивается.


Переход включается в итоговый список, если новая группа сохраняется в следующем месяце, минимальная поддержка на предыдущем, текущем и следующем срезах составляет не менее 0,8, а евклидов сдвиг в 13-мерном пространстве достигает 0,5. Порог поддержки требует как минимум восьми совпадений из девяти. Порог сдвига задаёт минимальный масштаб изменения в стандартизованных признаках.

Из 2 653 смен меток 1 337 сохраняют новую группу на следующем срезе. У 205 из них достаточная поддержка, а у 49 дополнительно выполнено условие величины сдвига. Отобранные события относятся к 40 территориям. Для декабрьских смен проверка сохранения группы невозможна из-за отсутствия января 2025 года. События вне итогового списка сохранены в полной таблице переходов.

Наименьшая устойчивость наблюдается в сентябре: медианный ARI девяти вариантов равен 0,361, минимальный 0,228. Численность C0 сокращается с 1 242 территорий в августе до 703 в сентябре и возрастает до 1 262 в октябре. Такая чувствительность требует проверки массовой перегруппировки по внешним данным, прежде чем связывать её с экономическим событием.

Минимальная поддержка	Сдвиг $\geq 0,25$	Сдвиг $\geq 0,50$	Сдвиг $\geq 0,75$
0,70	193	66	30
0,80	130	49	25
0,90	34	21	12

Число отобранных событий меняется от 12 до 193 на рассмотренной сетке. Значение 49 относится к порогам 0,8 и 0,5. Выбор порогов для прикладного мониторинга потребует проверки на новых месяцах и оценки допустимого объёма ручного анализа.



8. Переход территории ID 191

В справочнике ID 191 соответствует Юстинскому району Республики Калмыкия. В июле 2024 года территория переходит из C1 в C0. Минимальная поддержка за июнь, июль и август составляет 8/9, сдвиг признаков равен 1,584. Группа C0 сохраняется на следующих доступных срезах. Событие удовлетворяет условиям отбора.


Доля маркетплейсов увеличилась с 17,47% в июне до 20,84% в июле, или на 3,37 п.п. Одновременно выросла доля расходов на здоровье и снизилась доля прочих расходов. Общий показатель расходов увеличился с 22 422 до 23 059 руб. Эти изменения описывают несколько составляющих перехода в многомерном пространстве.

Годовой темп общих расходов остался близким к прежнему: 17,82% в июне и 17,85% в июле. Поэтому оснований связывать смену группы с ускорением совокупных расходов нет. Июльский silhouette составляет -0,116 при высокой поддержке метки; территория расположена в области перекрытия профилей.

Для объяснения перехода могут иметь значение состав покупателей в оценке источника, сезонность расходов и локальные изменения торговых каналов. Проверить эти предположения по используемому набору невозможно: сведений об открытии пунктов выдачи, доходах домохозяйств и событиях местной экономики в нём нет.

У ID 401, Бай-Тайгинского района по тому же справочнику, переходы C1 в C0 проходят фильтр в апреле и октябре. Повторная смена показывает ограниченность временного окна проверки. Для оценки долгосрочного изменения профиля необходима более продолжительная история наблюдений.

Юстинский район (ID 191): переход C1 в C0 в июле



9. Расстояния и доступность рынков


Декабрьская экономическая сеть содержит 61 259 неориентированных рёбер. Для 60 708 из них известно дорожное расстояние. В этой подвыборке 49,94% связей соединяют муниципальные центры, удалённые более чем на 1 000 км; медианное расстояние составляет 998 км. Рёбра с пропущенными расстояниями исключены только из данного расчёта.

Экономически близкие территории часто расположены далеко друг от друга. Файл `peers_december.csv` содержит для каждого муниципалитета пять ближайших профилей внутри его декабрьской группы, расстояния в пространстве признаков и дорожную удалённость. Этот список позволяет расширить географию сравнительного анализа. Применимость опыта другой территории требует отдельной содержательной оценки.

Индекс доступности рынков использован для внешнего сопоставления. Декабрьские группы объясняют 31,9% выборочной вариации $\log(1 + \text{market_access})$ по показателю η^2 -squared. Медиана у 200 случайных перестановок меток равна 0,00074. Перестановки не сохраняют пространственную зависимость; расчёт имеет описательный характер, p -value не приводится.

Медианы исходного индекса в C0, C1 и C2 равны 318,2, 294,7 и 515,9 соответственно. Связь с группами немонотонна: у C1 показатель ниже, чем у C0. Ранговая корреляция доступности рынков с долей маркетплейсов в декабре составляет 0,117. Одного показателя доступности недостаточно для объяснения структуры потребления и распространения дистанционной торговли.

Дорожные расстояния связей экономической сети



10. Применение и воспроизводимость

Результаты предназначены для сравнительного анализа муниципалитетов. Карточка территории показывает структуру расходов и историю группы; список аналогов даёт ориентиры для сопоставления; таблица переходов выделяет события для дальнейшего изучения. В практической работе каждое событие может сопоставляться с независимыми источниками и местной статистикой. Экономический эффект применения инструмента пока не измерялся.

Автономная страница `site/index.html` содержит выбор месяца, поиск территории, фильтры группы и поддержки, проекцию PCA, профиль расходов и список переходов. Координатная система PCA оценена на срезах настройки и зафиксирована во времени. Две оси сохраняют 55,96% дисперсии обучающего пространства. При оценке близости территорий приоритет имеет исходное 13-мерное расстояние.

Расчёт запускается по JSON-конфигурации. Исходные данные включены с лицензией и контрольными суммами. Девять тестов проверяют формулы метрик на малых графах, симметрию сети, обработку неизвестных расстояний, сопоставление меток, сохранение расщеплений и отсутствие влияния последних трёх месяцев на более ранние признаки. Повторные запуски в одной программной среде совпали по девяти таблицам и семи массивам при $rtol = 1e-10$ и $atol = 1e-12$. Время выполнения исключено из сравнения.

Область применения ограничена покрытием исходного набора, отсутствием весов населения и региональных дефляторов, слабой делимостью групп и чувствительностью к параметрам. Вторичный справочник названий требует проверки при переходе к конкретной территории. Независимая разметка и данные для установления причин изменений отсутствуют.

Развитие исследования предполагает сопоставление с официальными показателями при согласованных границах, сравнение экономического и географического разбиений при одинаковом числе групп, оценку устойчивости на новых месяцах и ручную проверку событий. Отдельный вопрос связан с временной регуляризацией: насколько она уменьшит нестабильность и какие наблюдаемые переходы при этом сгладит.

Исходные и производные данные распространяются по CC BY-SA 4.0, код проекта по MIT. Полный перечень источников приведён в `SOURCES.md`. Выводы относятся к потреблению за 2023–2024 годы.